目录

一、项目背景 - 1 -
1.1 整体背景 - 1 -
1.2 公司背景 - 1 -
1.3 业务背景 - 1 -
二、绪论 - 1 -
2.1 国内外研究现状 - 1 -
2.2 面临的问题与难点 - 2 -
三、医保数据特征工程 - 3 -
3.1 评估数据整齐度 - 3 -
3.2 评估数据干净度 - 3 -
3.3 缺失值处理 - 4 -
3.4 重复值处理 - 5 -
3.5 归一化处理 - 5 -
3.6 独热编码 - 6 -
3.7 特征选择 - 7 -
3.8 PCA 降维 - 9 -
3.9 总结 - 12 -
四、模型的建立与求解 - 13 -
4.1 样本不平衡问题的处理 - 13 -
4.2 机器学习模型的选择 - 15 -
4.3 模型的训练与参数优化 - 18 -
4.4 基于 SHAP 和 LIME 的可解释性呈现 - 21 -
五、业务实践与附加价值探索 - 24 -
5.1 业务实践角度的模型价值 - 24 -
5.2 附加价值的拓展和丰富 - 25 -
5.3 结论 - 26 -

一、 项目背景

1.1 整体背景

社会医疗保险是国家通过立法形式强制实施，由雇主和个人按一定比例缴纳保险费，建立社会医疗保险基金，支付雇员医疗费用的一种医疗保险制度，它是促进社会文明和进步的重要手段。但是，有些人为了获得不当利益，利用各种途径收集医疗保险参保人员的医保卡，通过医保卡到医院进行虚假诊疗，或通过编造病历、诊疗过程，套取医保基金，不仅危害社会，也让自己走上犯罪的道路，终是害人害己。

1.2 公司背景

东软面向全球市场提供 IT 驱动的创新型解决方案与服务，致力于推动社会的发展与变革，为个人创造新的生活方式，为社会创造价值。公司创立于 1991 年，目前拥有近 30000 名员工，在中国建立了 8 个区域总部，10 个软件研发基地，16 个软件开发与技术支持中心，在 60 多个城市建立营销与服务网络；在美国、日本、欧洲、中东、南美设有子公司。东软是中国第一个上市的软件公司，也 16 个软件开发与技术支持中心，在 60 多个城市建立营销与服务网络；在美国、日本、欧洲、中东、南美设有子公司。东软是中国第一个上市的软件公司，也是最先通过 CMM5 和 CMMI(V1.2)5 级认证的中国软件公司。

1.3 业务背景

在大数据和人工智能领域，东软依托 UniEAP 业务基础平台、SaCa 云应用平台、RealSight 大数据高级分析应用平台，快速构建行业解决方案，开拓基于大数据的新型业务模式与应用，帮助企业实现互联网化转型。

二、 绪论

2.1 国内外研究现状

医保欺诈是指个人或组织为获得基本医疗保险基金支付的不法利益，故意虚假陈述、隐瞒事实的违法行为，医疗欺诈行为直接侵害了广大参保人员的利益，甚至导致医保基金流失，影响医疗保障基金的安全运行。因此，国内外的学者一直聚焦于使用各类模型来直接或间接地辨别医疗欺诈的情况。目前的医保异常检测的主流方向是有监督学习算法与无监督学习算法。

国内外许多学者利用有监督学习算法构建异常检测模型时应变量的标签信息来实现较好的预测效果。例如，Hongxing He 等[1]将专家顾问与全科医生样本的实践概况从正常到异常分类为四类训练多层神经网络。Karca Duru Aral 等[2]通过贝叶斯、决策树、神经网络等算法开发医保异常检测模型，能有效地判断医保数据的异常。因为研究起步时间等原因，国内的研究相比国外稍显滞后。王超等[3]运用自组织竞争型神经网络(SOM)与 BP 神经网络相结合，研究成果较好地实现了对医保欺诈行为的主动识别。狄萱[4]提出一种基于加权孤立森林算法的无监督医保欺诈识别模型，利用孤立二叉树的路径长度标准差对孤立森林算法中异常分值计算公式进行加权改进,并基于 Spark 平台实现加权孤立森林算法并行化；同时提出一种基于混合采样与特征选择的加权随机森林算法。

在监督机器学习方法中，数据标签通常来自积累的历史欺诈案例。针对医疗保险欺诈检测，基于监督学习的方法首先由经验丰富的医疗保险专家根据医学知识识别欺诈数

据，并进行欺诈标签标注，然后使用监督学习算法来辨识欺诈行为。然而，由于欺诈行为的主体具有多样性，以及对于新型欺诈行为的认知在已有欺诈案例中存在滞后，监督学习只能通过历史欺诈数据的标签来训练模型，从而仅能识别出已知模式的欺诈数据，无法辨别新型欺诈数据。

面对多样且隐蔽的医疗保险欺诈和违规手段，单一算法的异常检测存在一些不足之处。为了提升算法的效果，学者们陆续结合多种算法进行异常检测和模式识别的研究。例如，国内学者林杰新[5]针对模式识别中单独使用无监督或有监督方法的不足，提出了一种先聚类后分类的思想，并通过对真实数据的分析验证了该结合模型的可行性和高效性。此外，国外学者 Halgamuge S K 等[6]提出了一种结合模糊逻辑和神经网络的自动分类模型，并通过实验验证了该模型的良好性能。这表明不同算法的结合可以产生良好的效果，并在医疗保险欺诈检测方面具有潜力。

2.2 面临的问题与难点

通过对医保异常检测的研究情况进行分析可知，当前的医保异常检测工作主要存在以下几大问题和难点：

（1）医保样本的特征数量较多且特征间存有冗余信息，如何选取合适的特征。

信息化的大力发展使得医疗保险信息系统中存储了大量的医保数据，从医保系统中提取的样本数据含有较多的特征变量，在这些特征变量当中存有不少变量与所要研究内容不相关，比如患者姓名、联系电话等等，所以特征选取之前应该先剔除这些与研究无关的变量。另外挑选出的特征变量之间可能存在耦合情况，如果将这些变量全都用于实验当中，会对检测算法的运行速度和效果产生一定的影响。

因此如何对医保样本进行无关变量剔除、特征降维、消除变量冗余信息是当前医保异常检测研究应重视的问题。

（2）医保异常、正常样本占比相差很大，如何实现医保正负样本平衡化。

现实生活中医保欺诈及违规行为相对于医保正常行为来说比例非常小，这也就导致了医保异常样本的数量远远小于正常样本数量，从而造成了数据不平衡现象。如果不考虑这一实际情况直接采用分类算法进行训练得到分类模型，那么这个分类模型的效果会受到很大影响。

正常情况来说分类模型要求有均匀的样本集，对于非平衡样本数据集训练出的分类模型趋向于高准确预测数量级大的类别，而对数量级小的类别预测就没那么准了，但医保异常检测研究的主要目的是检测出占比较小的医保异常样本，因此如何在非平衡的样本数据集中建立高效实用的异常检测模型是一个需重点研究的问题。

（3）针对当前繁杂多样且隐蔽的欺诈违规行为，如何设计出一个高效实用的医保异常检测模型。

当前的医保欺诈及违规行为形式多样且极其隐蔽，给医保经办部门的工作造成了很多困难。针对医保欺诈及违规问题，国内外许多学者进行了相关研究并提出各种各样的异常检测方法， 目前对于医保异常检测的方法主要集中在聚类算法或分类算法上，这两类方法在使用过程中都存有各自的一些不足， 因此如何克服这两种算法在医保异常检测研究中的不足，构建出高效实用的异常检测模型意义重大。

三、 医保数据特征工程

3.1 评估数据整齐度

根据埃德加·科德（Edgar F. Codd）的第三范式，数据的整齐度主要有“每列是一个变量，每行是一个观察值，每个单元格是一个值”这三个标准。

从题目给出的原始数据集中随机抽样 5 行数据进行检查，部分特征如表 1 所示。

表 1 数据抽样部分特征展示

#	个人编码	月就诊天数_MAX	月药品金额_MAX	医院_药品_MAX	个人账户金额_SUM	药品在总金额中的占比	个人支付的药品占比	RES
1916	3.52E+14	5	2707.69	12147.49	1331.38	0.931235334	0.002464707	0
8814	3.52E+14	12	3445.3	12649.43	1541.9	0.976190019	0.003116046	0
10778	3.52E+14	6	2321.25	10988.07	1369.43	0.934186125	0.000869375	0
12846	3.52E+14	4	1733.57	3831.06	6960.56	0.168391914	0.033340698	0
14610	3.52E+14	5	3365.17	8522.07	335.49	0.809304527	0.017094435	0

对随机抽样的 5 行数据进行检查，符合“每列是一个变量，每行是一个观察值，每个单元格是一个值”等标准，具体来看每行表示一个患者全部的就诊信息，每列是就诊相关的各个变量，包括就诊次数，付费等，因此不存在结构性问题。

3.2 评估数据干净度

对问题给出的原始数据集进行整体内容评估，部分结果如表 2 所示

表 2 原始数据集内容评估部分结果

#	Column	Non-Null Count	Dtype
0	个人编码	16000 non-null	int64
1	一天去两家医院的天数	16000 non-null	int64
2	就诊的月数	16000 non-null	int64
3	月就诊天数_MAX	16000 non-null	int64
4	月就诊天数_AVG	16000 non-null	float64
5	月就诊医院数_MAX	16000 non-null	int64
6	月就诊医院数_AVG	16000 non-null	float64
7	就诊次数_SUM	16000 non-null	int64
8	月就诊次数_MAX	16000 non-null	int64
9	月就诊次数_AVG	16000 non-null	float64
10	月统筹金额_MAX	16000 non-null	float64
……	……	……	……
80	是否挂号	16000 non-null	int64
81	RES	16000 non-null	int64

原始数据集共有 16000 个样本，82 个特征（包括 RES 标签），对这些特征进行分析，可得：

（1）第 0 个特征：个人编码数据全部一致，可以删除。

（2）第 1~19 个特征：天数、次数、金额等，数值变量，该部分特征无明显错误。

（3）第 20 个特征：医院编码_NN 应为分类变量，这里为 int64 数值类型。

（4）第 21-24 个特征：顺序号_NN，交易时间 DD_NN，交易时间 YYYY_NN，交易时间 YYYYMM_NN 均为抽取的其中一次交易记录，且这四个特征经过脱敏处理后没有特殊意义，对后续模型建立无较大影响，可以删除。

（5）第 25 个特征：住院天数_SUM，全为 0，可以删除。

（6）第 26~80 个特征：为各种支付金额，存在较大相关性。其中 70 出院诊断病种名称，78 BZ_民政救助、79 BZ_城乡优抚、 80 是否挂号 应为分类变量，71 住院诊断 LENTH_MAX 存在缺失值。

（7）第 81 个特征：欺诈结果，为 1 则表示欺诈。

对上述内容进行总结：

① 总体来说只有第 1~19 和 26~80 等特征具有实际意义，对模型构建影响较大，且之中存在较强相关性，需要降维处理。
② 个人编码，顺序号_NN，交易时间 DD_NN，交易时间 YYYY_NN，交易时间 YYYYMM_NN 这 5 个特征脱敏处理后无实际意义，对模型构建无较大影响，可以直接删除。
③ 某些特征高度重复，需要进行低方差滤波。
④ 医院编码_NN、出院诊断病种名称_NN、BZ_民政救助、BZ_城乡优抚、是否挂号为分类变量，应进行独热编码。

3.3 缺失值处理

由上述分析得第 71 个特征：住院诊断 LENTH_MAX 存在缺失值，对该列数据进行描述性统计，如表 3 所示。

表 3　LENTH_MAX

count	15645
mean	26.032279
std	12.353055
min	2
25%	17
50%	25
75%	34
max	86

由表 3 得 LENTH_MAX 列只有 15645 个数据，总样本量为 16000，有 355 个样本存在缺失值。常用的缺失值处理主要包括均值填补，中位数填补，众数填补，由于该列数据平均值为 26.032279（小数），本文采用中位数 25 进行缺失值处理。

3.4 重复值处理

对数据进行检查后发现第 1322 和第 3518 个样本完全一致，部分特征如表 4 所示。为了最大化程度减小过拟合风险，对后面重复的样本进行删除处理，删除后数据集中共计 15999 个样本。

表 4 重复值检验

#	一天去两家医院的天数	就诊的月数	月统筹金额_MAX	个人账户金额_SUM	ALL_SUM	可用账户报销金额_SUM	治疗费用在总金额占比	是否挂号	RES
1322	0	1	248.9	27.66	276.56	27.66	0.061469	0	0
3518	0	1	248.9	27.66	276.56	27.66	0.061469	0	0

3.5 归一化处理

分析原始数据集特征可以发现，不同类型的特征变量取值范围相差很大，例如就诊天数的取值范围一般不会超过 100，比例甚至不会超过 1，但是各类就诊费用却高达几千甚至上万，如果直接使用这些特征数据进行建模会导致模型偏好数值较高的这些特征，从而造成结果的误差。因此为了减小变量取值范围相差较大的影响，需要对特征变量进行无量纲化处理。

常用的无量纲化方法主要有 Min-Max 归一化和 Z-score 标准化：

（1）Min-Max 归一化

该方法是对原始的特征变量进行归一化， 将所有的数值映射到[0,1]之间。

$$x^* = \frac{x - \min(x)}{\max(x) - \min(x)}$$

（2）Z-score 标准化

该方法主要是对数据进行标准化，使得数据服从标准正态分布。

$$x^* = \frac{x - \mu}{\sigma}$$

在本文中，由于分类变量进行独热编码后全部为 0 或 1，故选用第一种方法对除了医院编码_NN、出院诊断病种名称_NN、BZ_民政救助、BZ_城乡优抚、是否挂号等分类变量和 RES 标签之外的所有**数值型数据**进行归一化处理，使得所有的医保变量数值都处于[0,1]之间。并且由中心极限定理得，当样本数据量足够大时，独立随机变量的均值趋于正态分布。

归一化之后的部分数据如表 5 所示

表 5 归一化后部分数据

#	就诊次数_SUM	月统筹金额_AVG	医院_药品_MAX	统筹支付金额_SUM	可用账户报销金额_SUM	药品费申报金额_SUM	治疗费申报金额_SUM
0	0.107843	0.067943	0.041948	0.121147	0.04104	0.070924	0.002505
1	0.045752	0.043776	0.050744	0.078055	0.029431	0.04639	0.002936
2	0.143791	0.06906	0.052964	0.123138	0.057587	0.062009	0.069253
3	0.071895	0.055015	0.027094	0.098095	0.030139	0.028011	0.145377
4	0.081699	0.05872	0.071407	0.104702	0.034383	0.064125	0.004698

3.6 独热编码

原始数据集共有 16000 个样本，81 个特征（不包括 RES 标签），去除重复值以及个人编码，顺序号_NN，交易时间 DD_NN，交易时间 YYYY_NN，交易时间 YYYYMM_NN 等 5 个无意义特征后，还剩 15999 个样本，76 个特征。

76 个特征中存在 71 个数值型变量，剩下的医院编码_NN、出院诊断病种名称_NN、BZ_民政救助、BZ_城乡优抚、是否挂号等 5 个特征均为分类变量。在这 5 个分类变量当中，医院编码_NN、出院诊断病种名称_NN 为多类别名义变量，即使其中的类别已经被转换为数字表示，但是在算法看来，这些特征值相互不等，有大小，并且有着可以相加相乘的联系。

这显然与数据的实际意义不符，对于这 2 个多类别名义变量，我们只有使用哑变量的方式来处理，才能够尽量向算法传达最准确的信息。

图 1 哑变量处理示意图

这样的变化，让算法能够彻底领悟，原来三个取值是没有可计算性质的，是“有你就没有我”的不等概念。在我们的数据中，性别和舱门，都是这样的名义变量。因此我们需要使用独热编码，将这 2 个多类别名义变量都转换为哑变量。

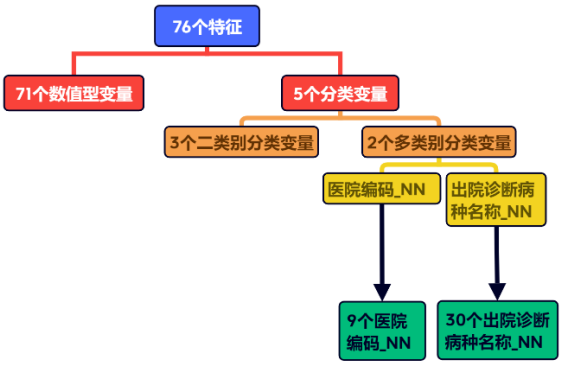

图 2 整体编码示意图

独热编码前医院编码_NN、出院诊断病种名称_NN 特征部分数据如表 6 所示，可以看到其中都包含多个类别值，需要进行独热编码。

表 6 独热编码前特征值部分数据

#	医院编码_NN	出院诊断病种名称_NN
0	3	4
1	2	3
2	3	4
3	2	5
4	1	2

对医院编码_NN、出院诊断病种名称_NN 这两个多类别名义变量进行独热编码，其中医院编码_NN 共有 9 个类别，出院诊断病种名称_NN 共有 30 个类别，因此在进行独热编码后 2 个多类别名义变量会被转换成 39 个哑变量，绘制词云图如图 3 所示。

图 3 哑变量词云图

3.7 特征选择

3.7.1 低方差滤波

数据集经过独热编码后共有 113 个特征（不含 RES 标签），这其中可能会有某个特征中的大多数值都一样，甚至整个特征的取值都相同，那这个特征对于样本区分没有什么作用，所以我们优先将其删除。

对所有特征进行方差检验，部分结果如表 7 所示

表 7 方差检验部分结果

个人账户金额	**0.002845**	月统筹金额_AVG	**0.002467**
就诊的月数	0.013652	月药品金额_MAX	0.001188
月就诊天数_MAX	0.019535	月药品金额_AVG	0.002111
月就诊天数_AVG	0.013561	医院_就诊天数_MAX	0.009653
月就诊医院数_MAX	0.018303	医院_就诊天数_AVG	0.006869
月就诊医院数_AVG	0.01458	医院_统筹金_MAX	0.008909
就诊次数_SUM	0.005976	医院_统筹金_AVG	0.006821
月就诊次数_MAX	0.004936	医院_药品_MAX	0.001773
月就诊次数_AVG	0.006169	医院_药品_AVG	0.002101
月统筹金额_MAX	0.004336	住院天数_SUM	0

由表 7 得住院天数_SUM 的方差为 0，表示其中的取值全部相同，对模型训练无意义，将其删除（个人编号同样方差为 0，已在上文中删除），此时共有 112 个特征。

3.7.2 互信息法

互信息是信息论中衡量两个随机变量之间相互依赖程度的指标，可以用来评估特征与目标变量之间的相关性。互信息的计算方法基于信息熵的概念，它衡量了两个随机变量联合分布与各自边缘分布之间的差异。

（1）原理

基于互信息值来衡量特征与目标变量之间的相关性，互信息值越大，表示特征对目标变量的贡献越大，具有更强的预测能力。通过选择互信息值最高的特征，我们可以提取出对目标变量最相关的特征，从而提高机器学习模型的性能。

（2）计算公式

在特征选择中，我们需要计算每个特征与目标变量之间的互信息，如公式 3 所示

$$I(X;\mathrm{Y})=\sum p(x,y)\times\log(p(x,y)/(p(x)\times p(y)))$$

其中，X 表示特征，Y 表示目标变量，$p(x)$ 表示特征 X 和目标变量 Y 的联合概率分布，$p(x)$ 和 $p(y)$ 分别表示特征 X 和目标变量 Y 的边缘概率分布。

（3）步骤

Step1: 计算每个特征与目标变量之间的互信息。对于每个特征 X 和目标变量 Y，使用公式 3 计算它们之间的互信息值。

Step2: 根据互信息值排序特征。将特征按照与目标变量的互信息值从大到小排序，以确定特征的重要性。

Step3: 根据排序结果，选择具有较高互信息值的特征。

（4）结果

经过计算，有 24 个特征的互信息小于等于 0，如表 8 所示。

表 8 互信息小于 0 的特征

检查费发生金额_SUM	**手术费申报金额_SUM**	**成分输血申报金额_SUM**	**其它发生金额_SUM**
最高限额以上金额_SUM	残疾军人补助_SUM	城乡优抚补助_SUM	检查总费用在总金额占比
医院编码_NN_1	医院编码_NN_3	医院编码_NN_5	出院诊断病种名称_NN_0
出院诊断病种名称_NN_3	出院诊断病种名称_NN_5	出院诊断病种名称_NN_11	出院诊断病种名称_NN_12
出院诊断病种名称_NN_14	出院诊断病种名称_NN_16	出院诊断病种名称_NN_20	出院诊断病种名称_NN_21
出院诊断病种名称_NN_22	出院诊断病种名称_NN_28	出院诊断病种名称_NN_34	出院诊断病种名称_NN_39

24 个特征互信息小于等于 0，说明对医保欺诈无较大影响，将其过滤后对剩下的 88 个特征使用未调参的随机森林模型对过滤前后的数据进行训练，对比结果如图 4 所示。

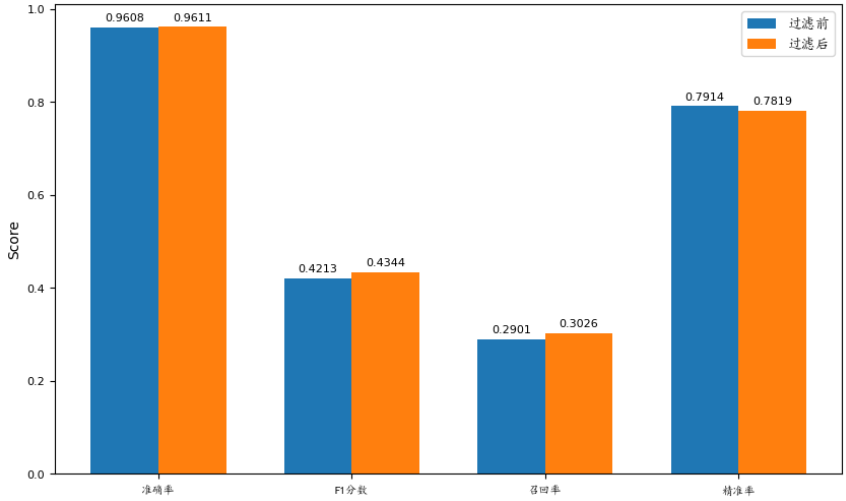

图 4 过滤前后效果对比

由图 4 得过滤后准确率、*F1* 分数、召回率等指标都有一定程度上升，因此，使用互信息法过滤掉 24 个互信息小于等于 0 的特征效果良好，过滤后共有 88 个特征。

3.8 PCA 降维

在进行医保特征提取的过程中，如提取后特征维数较多会导致模型训练时过于复杂，影响检测的效率。因此需要对初步筛选的变量进行降维处理，将相关性比较高的变量转化为彼此不相关的变量，为提高算法的运行效率做好准备。

主成分分析法（*PCA*）是一种常用的降维方法，运用该方法能够从原始变量中导出更少数量的主成分变量，在起到降维和消除变量冗余信息作用的同时保留了原始变量的绝大部分信息。

由于 *PCA* 不能够应用在离散变量中，故选择过滤后得到的 62 个连续数值型变量进行降维。

3.8.1 PCA 基本步骤

对 15999 个样本，62 个的特征变量，第 i 个样本关于 j 个指标取值为 a_{ij}，构造数据矩阵 $A=(a_{ij})_{15999\times 62}$

Step1: 对原来的 62 个指标进行标准化，得到标准化，得到标准化的指标变量

$$y_j=\frac{x_j-\mu_j}{s_j},\quad j=1,2,\cdots,62$$

其中，$\mu_j=\frac{1}{n}\sum_{i=1}^{15999}a_{ij}$，$s_j=\sqrt{\frac{1}{n-1}\sum_{i=1}^{15999}(a_{ij}-\mu_j)^2}$。对应地，得到标准化的数据矩阵 $B=(b_{ij})_{15999\times 62}$，其中 $b_{ij}=\frac{a_{ij}-\mu_j}{s_j},i=1,2,\ldots,15999,\ j=1,2,\ldots,62$。

Step2： 根据标准化的数据矩阵 B 求出相关系数矩阵 $R=(r_{ij})_{15999\times 62}$,其中

$$r_{ij}=\frac{\sum_{k=1}^{n}b_{ki}b_{kj}}{n-1},i,j=1,2,\ldots,62$$

Step3： 计算相关系数矩阵 R 的特征值 $\lambda_1\geq\lambda_2\geq\ldots\geq\lambda_{62}$， 及对应的标准正交化特征向量 $u_1,u_2,\ldots u_{62}$，其中 $u_j=\left[u_{1j},u_{2j},\ldots,u_{62j}\right]^T$，由特征向量组成 p 个新的指标变量

$$\begin{cases}F_1=u_{11}y_1+u_{21}y_2+\ldots+u_{(62)(1)}y_{62},\\ F_1=u_{12}y_1+u_{22}y_2+\ldots+u_{(62)(2)}y_{62},\\ \ldots\ldots\\ F_1=u_{(1)(62)}y_1+u_{(2)(62)}y_2+\ldots+u_{(62)(62)}y_{62},\end{cases}$$

式中 F_1 是第 1 主成分，F_2 是第 2 主成分,…, F_{62} 是第 62 主成分。

Step4： 计算主成分贡献率及累积贡献率，主成分 F_j 的贡献率为

$$w_j=\frac{\lambda_j}{\sum_{k=1}^{62}\lambda_k},j=1,2,\ldots,62$$

前 i 个主成分的累计贡献率为

$$\frac{\sum_{k=1}^{i}\lambda_k}{\sum_{k=1}^{62}\lambda_k}$$

一般取累积贡献率达 85%以上的特征值 $\lambda_1,\lambda_2,\ldots,\lambda_k$ 所对应的第 1、第 2、……、第 $k(k\leq 62)$ 主成分。

3.8.2 主成分选取

对于降维后确定的主成分个数，我们可以观察累积可解释方差贡献率曲线来确定。累积可解释方差贡献率曲线是一条以降维后保留的特征个数为横坐标，降维后新特征矩阵捕捉到的可解释方差贡献率为纵坐标的曲线，能够帮助我们决定主成分个数最好的取值。绘制出的可解释方差贡献率曲线如图 5 所示

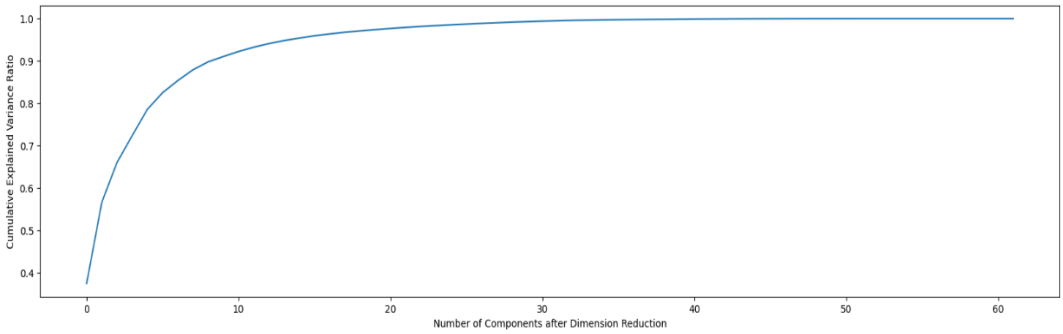

图 5 可解释方差贡献率曲线

由图 5 得

a) 选取主成分个数为 0~10 时，曲线上升较为陡峭。
b) 选取主成分个数为 10~20 时，曲线上升较为缓和。
c) 选取主成分个数>20 时，曲线趋于平稳

因此选取主成分为 10~20 进行训练，找出使分类效果最好的主成分个数。选取的模型为随机森林，设置随机数种子为 100，树的个数为 100，其余参数保持默认不变。进行 5 折交叉验证后绘制出学习曲线如图 6 所示。

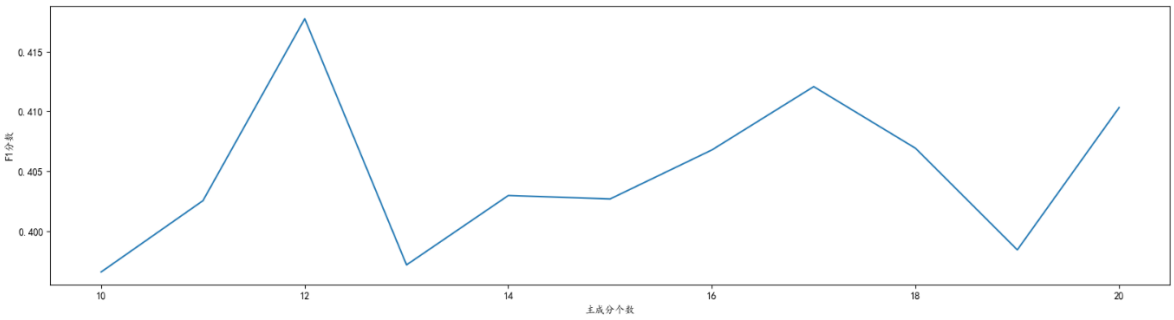

图 6 主成分个数与 F1 分数学习曲线

由图 6 得当选取主成分为 12 个时，模型的分类效果最优，同时挑选的主成分个数较少，减轻了模型训练负担。

3.8.3 降维结果

选取 12 个主成分进行降维，累计贡献率为 93.25%，说明降维后的新特征携带信息占原有信息的 93.25%，各主成分可解释性方差具体信息如表 9 所示。

表 9 各主成分可解释性方差

#	可解释性方差大小	可解释性方差贡献率	累计贡献率
1	0.1264	0.3751	0.3751
2	0.0645	0.1915	0.5667
3	0.0316	0.0938	0.6605
4	0.0214	0.0635	0.7239
5	0.0209	0.0621	0.786
6	0.0132	0.0392	0.8252
7	0.0096	0.0285	0.8537
8	0.0086	0.0255	0.8792
9	0.0063	0.0188	0.8979
10	0.0042	0.0125	0.9105
11	0.004	0.0119	0.9224
12	0.0034	0.0102	0.9325

确定了主成分之后，通过成分得分系数矩阵可以得到选取主成分在原始特征变量中的得分系数，以Y_i表示主成分i，X_j表示原特征j，最终的主成分表达式如下所示：

$$
\begin{cases}
Y_1 = 0.047X_1 + 0.0357X_2 + 0.2723X_3 + 0.2432X_4 + 0.0498X_5 + \cdots - 0.0118X_{66} \\
Y_2 = 0.1025X_1 + 0.1325X_2 + 0.308X_3 + 0.2387X_4 + 0.3485X_5 + \cdots - 0.0083X_{66} \\
Y_3 = -0.0414X_1 + 0.1672X_2 - 0.0872X_3 - 0.0478X_4 - 0.475X_5 + \cdots + 0.0097X_{66} \\
Y_4 = 0.0427X_1 - 0.0291X_2 - 0.3138X_3 - 0.2771X_4 + 0.3001X_5 + \cdots + 0.0451X_{66} \\
Y_5 = -0.012X_1 - 0.035X_2 - 0.1795X_3 - 0.122X_4 + 0.0418X_5 + \cdots - 0.0076X_{66} \\
Y_6 = 0.0549X_1 - 0.899X_2 + 0.0815X_3 + 0.0688X_4 - 0.1114X_5 + \cdots - 0.0089X_{66} \\
Y_7 = 0.0067X_1 + 0.0613X_2 + 0.0677X_3 + 0.0253X_4 - 0.0487X_5 + \cdots + 0.118X_{66} \\
Y_8 = -0.037X_1 - 0.2515X_2 + 0.0408X_3 + 0.0326X_4 - 0.0327X_5 + \cdots - 0.0865X_{66} \\
Y_9 = -0.032X_1 + 0.0631X_2 + 0.013X_3 + 0.0135X_4 + 0.0708X_5 + \cdots - 0.049X_{66} \\
Y_{10} = -0.0216X_1 - 0.0747X_2 - 0.0532X_3 + 0.039X_4 + 0.0406X_5 + \cdots + 0.5856X_{66} \\
Y_{11} = 0.0273X_1 + 0.0944X_2 + 0.0708X_3 - 0.0231X_4 - 0.0363X_5 + \cdots + 0.7472X_{66} \\
Y_{12} = 0.1928X_1 + 0.1299X_2 - 0.0395X_3 - 0.0572X_4 - 0.1147X_5 + \cdots - 0.148X_{66}
\end{cases}
$$

3.9 总结

对于特征工程部分，本文首先对各个特征进行分析，删除了一些无意义特征。其次对数据进行缺失值、重复值、归一化处理，接着对数据中多分类名义变量进行独热编码。然后分别通过低方差滤波和互信息法进行特征选择，过滤掉部分对模型分类性能影响不大的特征。得到 88 个特征变量，其中包括 62 个连续数值型特征变量和 26 个分类变量（包括经过编码之后的哑变量）。

最后对 62 个连续数值型特征变量进行 PCA 降维，消除变量冗余信息的同时保留了原始变量的绝大部分信息。经过 PCA 降维之后，62 个连续型数值变量被转换为 12 个主成分，而 26 个分类变量实质上是由 5 个分类变量编码而来，因此实质上经过特征工程后，影响医疗保险欺诈的特征因子只有 17 个。

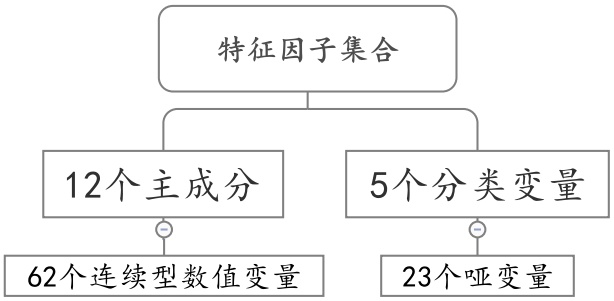

图 7 特征因子集合

经过特征工程后的部分最终数据如表 10 所示

表 10 特征工程后部分最终数据

#	主成分 1	主成分 2	主成分 3	……	是否挂号	医院编码_NN_2	出院诊断病种名称_NN_32	RES
0	0.140958189	0.465380914	0.296317598	……	1	0	0	0
1	0.085905115	0.395216808	0.339257121	……	1	1	0	0
2	0.211990315	0.427935678	0.252663441	……	0	0	0	0
3	0.253518531	0.270880881	0.204572746	……	0	1	0	0
4	0.12410007	0.401444516	0.407225891	……	0	0	0	0
……	……	……	……	……	……	……	……	……
15998	0.279348726	0.581678056	0.201395413		0	0	0	1

四、 模型的建立与求解

4.1 样本不平衡问题的处理

解决不平衡问题主要有 2 种方法：

1) 一种是使用更适合的评价指标，例如 *F1* 分数，它不仅考虑模型预测的错误数量，还考虑错误类型；
2) 另一种是使用特定的采样方法重新采样数据集，使数据平衡，例如基于 *RUSBoost* 的欠采样方法和基于 *SMOTE* 的过采样方法。

4.1.1 评价指标的选择

（1）准确率（*Accuracy*）

准确率是分类模型的一个指标，用于衡量正确的预测数量占所做预测总数的百分比。例如，如果 90%的预测是正确的，那么准确率就是 90%。

然而，在本题给出的原始数据集中，16000 个样本里面仅有 793 个欺诈样本（5%）。遇到不平衡数据时，准确率不是一个很好的指标。

可以想象，假如我们的模型将所有的样本全部预测为正常样本，那么它的准确率为 95%，但是这个模型并没有什么作用，因为它一个欺诈样本都没有识别出来。

（2）*F1* 分数（*F1 Score*）

F1 分数是查全率（*Recall*）和查准率（*Precision*）的调和平均数，计算公式如下

$$\frac{2}{F}=\frac{1}{R}+\frac{1}{P}$$

在本题中，查全率是指实际为欺诈的样本中预测正确的比例，查准率是指预测为欺诈的样本中预测正确的比例。可以看出，这两个指标与欺诈样本直接相关，更符合我们的预期目标，即尽可能识别出所有的欺诈样本。

但是，通常来说查准率和查全率是负相关关系的，二者一般不能同时提高。因此我们通过查准率和查全率的调和平均数——*F1* 分数作为模型的评价指标，并且该指标对于查准率和查全率的权重相等。

4.1.2 重采样方法的选择

（1）基于 *RUSBoost* 的欠采样方法

RUSBoost 算法结合了随机欠采样（*Random Under-Sampling, RUS*）和 *AdaBoost* 算法，核心思想是在每一次迭代中，通过随机欠采样的方式来减少多数类的数量，使得数据集在每个迭代中保持类别均衡，进而提高对少数类分类的准确性。

RUSBoost 的工作流程如下：

Step1:初始化数据集，确定 *AdaBoost* 的迭代次数。

Step2:在每一轮迭代中，执行以下步骤：

1) 从多数类中随机移除一定比例的样本，使得多数类和少数类的数量接近。
2) 使用当前的欠采样后的数据集训练一个弱分类器。
3) 根据分类结果更新样本权重，错误分类的样本将获得更高的权重。
4) 将新训练的弱分类器加入到集成模型中。

Step3:*经过若干轮迭代后，得到最终的集成模型。*

（2）基于 *SMOTE* 的过采样方法

SMOTE 是一种综合采样人工合成数据算法，核心思想是在少数类别的样本之间生成新的合成样本，从而增加少数类别的样本数量，使得数据集更加平衡。

SMOTE 的工作流程如下：

Step1: 选择样本，对于少数类别中的每一个样本，*SMOTE* 算法会在其 k 个最近邻中选择样本。k 的值通常是预先设定的，可以根据数据集的特点进行调整。

Step2: 生成合成样本，通过公式在每个少数类样本 x_i 和在其 k 个近邻中挑选得到的 N 个样本 $y_1, y_2, \cdots\cdots, y_N$ 之间进行插值（$N<=k$），这样一来就相当于给每一个少数样本都添加了 N 个新样本。

$$x_{new}=x_i+rand\left(0,1\right)\times\left(y_j-x_i\right), j=1,2,\cdots,N$$

其中，x_i 表示少数类别的样本点，y_j 表示从 x_i 的 K 个近邻中挑选到的样本点，$rand(0,1)$ 表示随机生成（0,1）之间的数。

Step3: 重复过程，这个过程会重复进行，直到生成足够数量的合成样本，使得少数类别的样本数量与多数类别的样本数量相等或者达到预设的目标。

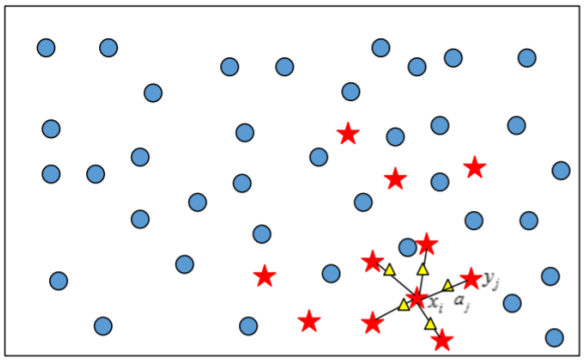

图 8 *SMOTE* 原理模拟图

图中，圆心点表示多数类样本点，五角星表示少数类样本点，三角形表示算法插值生成的新样本点。现假设图中 x_i 的样本值为$(6,1)$，y_j 的样本值为 $(7,1.8)$，$rand(0,1)$ 的取值为 0.4，对 x_i 和 y_j 进行插值操作，可得新 $x_{new}=(6,1)+0.4\times(7,1.8)=(8.8,1.72)$

（3）算法选择

分别对 *RUSBOOST* 模型和使用 *SMOTE* 过采样的随机森林模型进行简单训练，结果如图 9 所示。

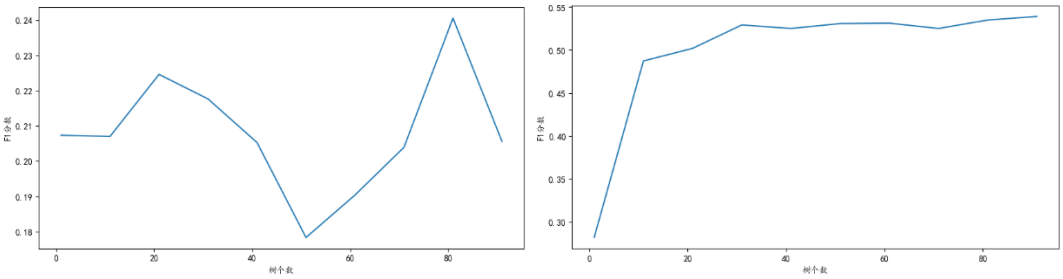

(a) *RUSBOOST* 训练结果　　（b）*SMOTE* 训练结果

图 9 *RUSBOOST* 和 *SMOTE* 训练结果对比

由图 9 得 *RUSBOOST* 训练后 *F1* 分数远低于 *SMOTE*，且欠采样方法是随机的剔除数据集中多数类的样本使得最终的正负样本达到平衡，这种方法虽然操作简单，但是在剔除样本时有可能会删掉一些重要的信息，故选择 *SMOTE* 方法进行过采样。

4.2 机器学习模型的选择

解决完数据集本身具有的不平衡问题后，已经可以初步开始构建医疗保险欺诈识别模型。对于模型的构建，选择一个合适的机器学习分类模型是十分关键且重要的一步，为此，可以将数据集代入不同分类模型中训练，根据不同模型的测试结果，根据准确率和 *F1* 值、*ROC* 曲线等指标，判断模型分类的性能优劣。

为了更精准地选出合适的分类模型，选择下列十种机器学习分类模型进行各种指标的计算与输出：

1) 逻辑回归（*Logistic Regression*）
2) 线性判别（*Linear Discriminant Analysis*，*LDA*）
3) K 近邻（*K-Nearest Neighbors*，*KNN*）
4) 决策树（*Decision Tree*）
5) 随机森林（*Random Forest*）
6) 梯度提升（*Gradient Boosting Machine*，*GBM*）
7) 极端梯度提升（*Extreme Gradient Boosting*，*XGBoost*）
8) 轻量梯度提升（*Light Gradient Boosting Machine*，*LightGBM*）
9) 支持向量机（*Support Vector Machine,SVM*）
10) 神经网络（*Neural Network*，*NN*）

4.2.1 不同模型准确率、*F1* 值

将数据集分别代入十种模型实例化，在统一默认参数的条件下充分训练，然后输入测试集数据返回预测结果，并与真实分类结果对比，计算得到不同模型的准确率、*F1* 值等指标，如表 11 所示：

表 11 十种模型四项指标值

	Accuracy	*Precision*	*Recall*	*F1_score*
逻辑回归	0.954063	0.54955	0.386076	0.453532
线性判别	0.944688	0.440252	0.443038	0.44164
K 近邻	0.92625	0.278409	0.310127	0.293413
决策树	0.89875	0.225166	0.43038	0.295652
随机森林	0.963437	0.715789	0.43038	0.537549
梯度提升	0.954063	0.543307	0.436709	0.484211
极端梯度提升	0.94875	0.478571	0.424051	0.449664
轻量梯度提升	0.954375	0.544118	0.468354	0.503401
支持向量机	0.959063	0.736842	0.265823	0.390698
神经网络	0.948125	0.469697	0.392405	0.427586

可以看出，十种模型的准确率都处于一个很高的值域，查全、查准率互为反比，不易作为评价指标，所以将 *F1* 值作为不同模型最终的评价指标。将不同模型的准确率与 *F1* 值以更加直观的柱状图形式展示，如图 10 所示：

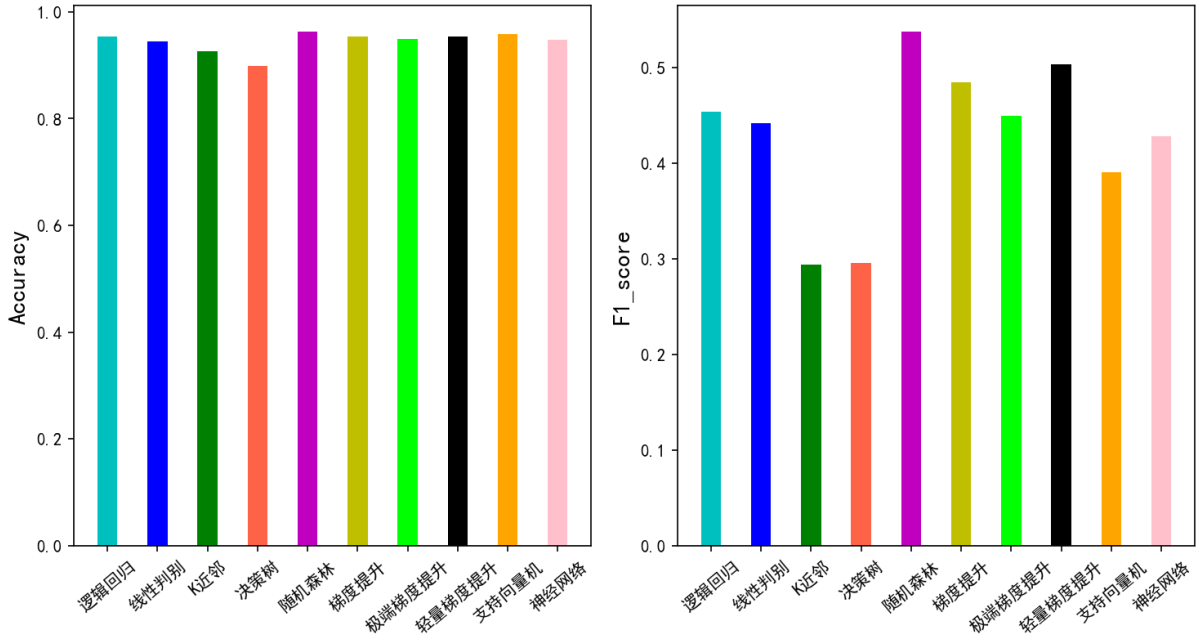

图 10 十种模型准确率和 F1 值

从上述图表中分析可知，在十种分类模型的准确率值都接近于 1 的情况下，初步认为 F1 值较高的随机森林分类模型是对于本项目数据集的最优模型。

4.2.2 不同模型 ROC 曲线

ROC 曲线全称为受试者工作特征曲线（*receiver operating characteristic curve*），它是根据一系列不同的分类阈值，以真正类率(*True Postive Rate, TPR*)为纵坐标，假正类率（*False Positive Rate, FPR*）为横坐标绘制两者之间关系的曲线。

真正率是正例中被正确预测为正例的比例，即：

$$TPR = \frac{TP}{TP + FN}$$

而假正率是负例中被错误预测为正例的比例，即：

$$FPR = \frac{FP}{FP + TN}$$

在二分类问题中，通常将正例看作正样本，负例看作负样本。假设我们有 m 个正例和 n 个负例，分类器的输出结果可以表示为一个 $m+n$ 维向量。向量中前 m 个元素表示正样本的预测概率，后 n 个元素表示负样本的预测概率。通过对这些预测概率进行排序，并逐一将其作为阈值进行分类，我们可以得到一系列的真正率和假正率，并绘制成 ROC 曲线。

AUC (Area Under Curve) 被定义为 *ROC* 曲线下的面积，取值范围一般在 0.5 和 1 之间。AUC 值通常作为评价标准比较不同分类模型的性能，简单来说，*AUC* 值越大，模型的分类效果越好，检测结果越准确。

在准确率和 *F1* 值初步筛选模型的基础上，通过不同模型的 *ROC* 曲线和 *AUC* 值，进一步确认合适的学习模型。不同模型的 *ROC* 曲线与 *AUC* 值如下图 11 所示：

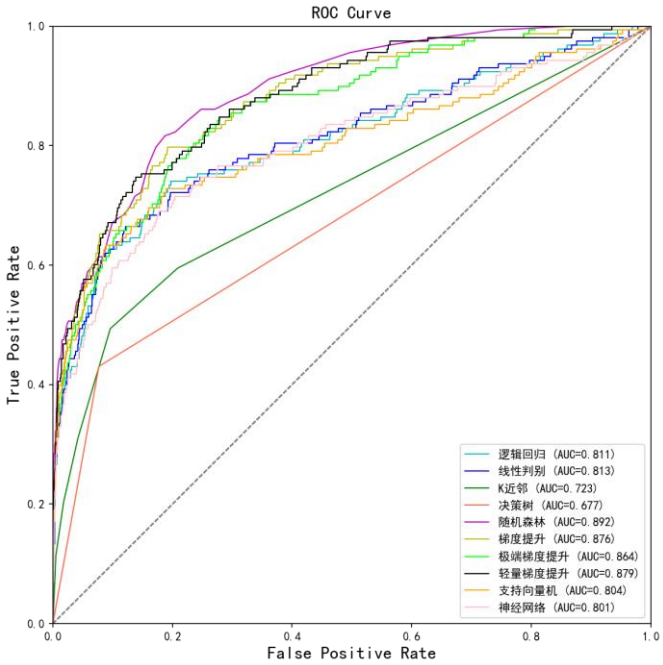

图 11 十种模型 *ROC* 曲线及 *AUC* 值

可以看出，*AUC* 值最高的两种模型为随机森林和梯度提升，两者仅相差 0.02。结合准确率与 *F1* 值两个指标综合考量，可以确定随机森林模型的综合效果最佳，故选择随机森林模型构建本项目的医疗保险欺诈识别模型。

4.3 模型的训练与参数优化

选择出最适合本项目的机器学习分类模型后，开始对模型进行训练与参数调优，这一环节关系到模型是否可以准确地学习到相关内容并进行输出分类结果，因此需要具体了解分类模型实现和选择合适的参数优化方法。

4.3.1 随机森林实现分析

随机森林是非常具有代表性的 *Bagging* 集成算法，它的所有基评估器都是决策树，它是用随机的方式建立一个森林，森林由很多的决策树组成，且每一棵决策树之间是没有关联的；通过使用有放回抽样方式从原始数据集中选择数据集样本，并随机从数据属性中选取属性用于每个决策树节点的分裂；随机森林会按照每棵决策树的分类结果进行投票，最终投票结果最多的类别，就是最终的模型预测结果。

因此随机森林模型的构建本质上是一定数量树模型的形成，而对于树形成的控制，拥有许多的参数。结合树模型的数量，可以得到影响随机森林性能的主要参数有：

1) *n_estimators*：随机森林中树模型的个数，即基评估器的数量；
2) *criterion*：不纯度的衡量指标，有基尼系数和信息熵两种选择；
3) *max_depth*：树的最大深度，超过最大深度的树枝都会被剪掉；
4) *min_samples_leaf*：每次分枝后子节点所需包含训练样本的最少值；
5) *min_samples_split*：每个节点分枝所需包含训练样本的最少值；
6) *max_features*：树模型分枝时考虑的特征个数；
7) *min_impurity_decrease*： 限制信息增益的大小的数值，信息增益小于设定数值的分枝不会发生。

4.3.2 模型训练

将划分好的训练集数据代入随机森林模型，保持各参数为默认值不变，即：$n_estimators = 100$，$criterion = gini$，$max_depth = None$，$min_samples_leaf = 1$，$min_samples_split = 2$，$max_features = None$，$min_impurity_decrease = 0$，同时设置随机数种子为 100，进行初步的模型训练，接着代入测试集数据的属性列，返回预测的分类结果与测试集中分类标签对比、计算得到此时模型的准确率和 *F1* 值，如表 12 所示：

表 12 默认参数随机森林准确率及 F1 值

准确率	F1 值
0.9634375	0.5375494

此时，模型的准确率虽然很高，但是 *F1* 值只处于 0.5 附近，模型性能仍有欠缺。为此，改变参数 *n_estimators* 的取值，计算不同情况下的 *F1* 值，绘制随机森林模型的学习曲线图，如图 12 所示：

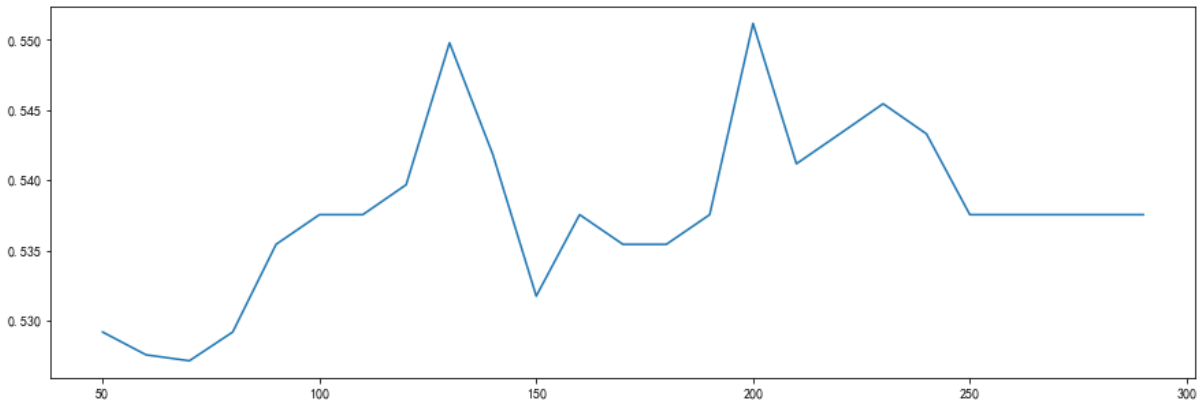

图 12 参数 n_estimators 不同取值 F1 值波动曲线

可以看出，参数的不同取值对于模型的效果影响较大，还需要选择合适的优化方法进行参数优化，以得到更优的模型效果。

4.3.3 粒子群优化算法

粒子群算法（Particle Swarm Optimization, PSO）是一种强大的智能优化算法，其算法策略是在搜索空间中随机初始化一群粒子的位置和速度，然后根据每个粒子的速度、问题空间中已知的最优全局位置和粒子已知的最优位置依次更新每个粒子的速度和位置，逐步靠近最优解。

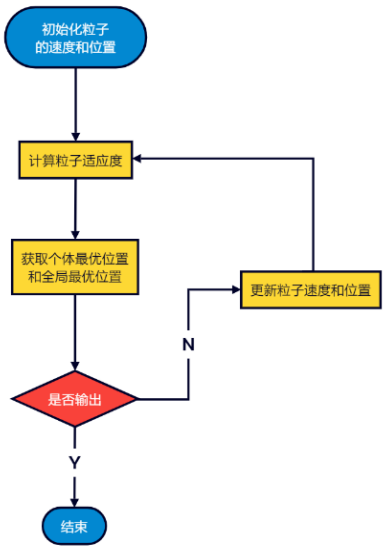

图 13　PSO 流程图

PSO 中每次迭代粒子 i 的速度 v_i 和位置 x_i 更新公式为:

$$v_i^k = wv_i^{k-1} + c_1 r_1 * rand() * \left(pbest_i - x_i^{k-1} \right) + c_2 r_2 * rand() * \left(gbest - x_i^{k-1} \right)$$

$$x_i^k = x_i^{k-1} + v_i^k$$

其中，w 为惯性权重（*inertia weight*），c_1 和 c_2 为加速常数（*acceleration constants*），$rand()$ 为在[0,1]范围里变化的随机值，*pbest* 为粒子自身的最佳过去位置，*gbest* 为整个群或近邻的最佳过去位置。

采用粒子群算法优化随机森林模型的参数，可以将模型返回预测结果计算得到的 F1 值作为目标函数，通过更新迭代得到最佳位置，即最优参数。

本项目中，在采用粒子群算法的基础上，还引入了惯性权重线性递减和多样性维护参数的概念，对算法加以改进。其中惯性权重 w 线性递减，根据迭代进度，逐渐减小惯性权重，可以在一定程度上优化粒子的寻优能力；多样性维护参数 c_3 可以确保种群中的粒子保持一定的多样性，避免陷入局部最优解。

$$w = w_{\max} - \frac{t}{T}\left(w_{\max} - w_{\min} \right)$$

$$V = c_3 * \left(Rand() - 0.5 \right) * range$$

$$v_i^k = v_i^k + V$$

其中，$w_{\max} = 0.9$，$w_{\min} = 0.4$，t 为当前迭代次数，T 为最大迭代次数，$c_3 = 0.1$，V 为多样性维护项，*range* 为各参数取值范围长度。

4.3.4 参数优化

通过对随机森林各参数的数值类型和取值范围的分析，选择出 *n_estimators*、*max_depth*、*min_samples_leaf*、*min_samples_split* 四个参数作为训练目标，接着根据随机森林的训练、预测和计算 *F1* 值等步骤建立目标函数为 *F1* 值高的优化模型，模拟粒子在求解空间中移动寻找全局最优解，通过多次迭代后，输出此时的最优解。模型预测结果的 *F1* 值随迭代次数变化曲线图如图 14 所示：

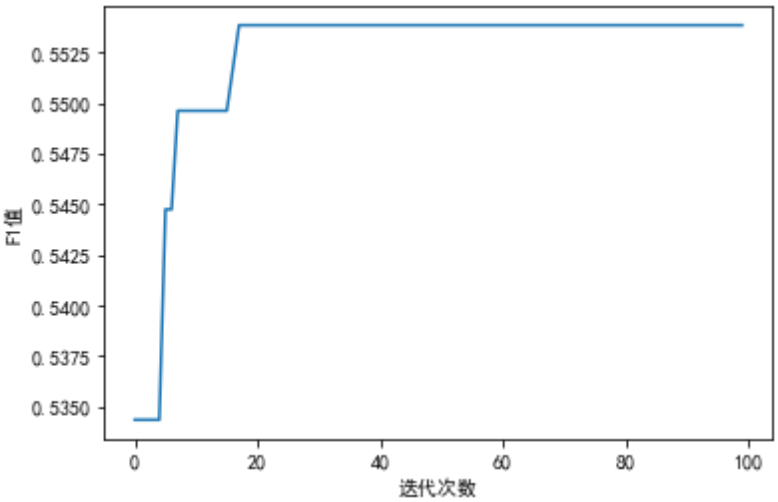

图 14 模型预测结果的 *F1* 值随迭代次数变化曲线

经过粒子群算法优化，可以得到模型的最优参数取值为 $n_estimators = 143$，$max_depth = 29$，$min_samples_leaf = 1$，$min_samples_split = 2$，此时模型的分类报告如表 13 所示：

表 13 最优参数下模型的分类报告

	Precision	*Recall*	*F1-score*	*Support*
0	0.9723	0.9915	0.9818	3042
1	0.7347	0.4557	0.5625	158
Accuracy			0.9650	3200

相较于优化前的模型，此时准确率（*Accuracy*）为 0.9650，*F1* 值为 0.5625，查准率为 0.7347，查全率为 0.4557，相较于调优前分类性能得以有效提升。

最终的分类模型对于给定医保欺诈样本可以达到 96.50%的准确率，同时对于其中的少样本（欺诈样本），预测为欺诈的样本中预测正确的比例达到了 73.47%（查准率），实际为欺诈的样本中预测正确的比例达到了 45.57%（查全率）。

4.4 基于 *SHAP* 和 *LIME* 的可解释性呈现

可解释性对于机器学习模型至关重要，因为它可以帮助理解模型的决策过程、预测结果以及特征的重要性。通过了解模型背后的逻辑和推理过程，可以提高对模型预测的信任度，并且能够更好地发现模型的局限性和潜在的偏差，从而更好地应对不确定性。

4.4.1 基于 *SHAP* 的可解释性呈现

*SHAP (SHapley Additive exPlanations)*基于博弈论，是一种模型无关的机器学习解释方法，既能衡量单次预测结果中的特征贡献，也能聚合局部结果成为对模型的整体解释。*SHAP* 的工作原理是通过对特征重要性进行评估，解释模型对每个特征的贡献，它使用了 *Shapley* 值衡量每个特征对预测结果的影响程度。并且相比其他解释器，SHAP 的优势有以下几点：

1) 高效计算：*SHAP* 通过优化算法，有效地减少了计算 *Shapley* 值所需的时间和资源。相比传统的计算方法，*SHAP* 能够在可接受的时间内解释复杂模型。
2) 可扩展性：*SHAP* 适用于各种类型的机器学习模型，包括神经网络、随机森林等。它具有很好的通用性，可以广泛应用于不同领域和问题。
3) 解释性准确性：*SHAP* 提供了对模型预测结果解释的准确性和可信度。通过计算每个特征的 *SHAP* 值，可以了解到每个特征对预测结果的贡献程度，从而更好地理解模型的决策过程和关键特征。

本项目在模型训练、参数优化、数据聚类等步骤完毕的基础上，对较为成熟的模型选用 *SHAP* 解释器进行可解释性地分析与呈现。

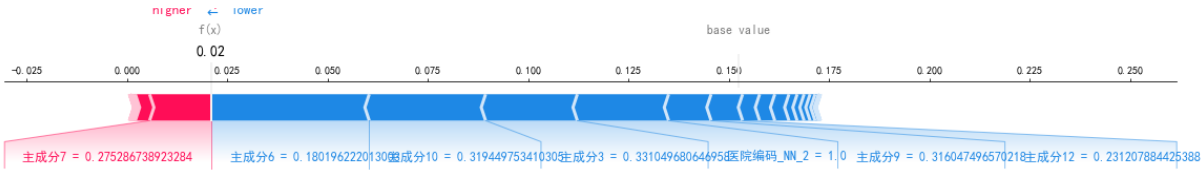

图 15 基于 SHAP 的单样本解释

上图是随机抽取单样本的分类结果贡献图，展示了每个特征的贡献程度，图上有基准值（*base value*）以及最终的分类结果概率 *f(x)*值，红色表示为正向作用，蓝色表示为负向作用。

通过查阅数据发现上图抽取单样本的分类结果为 0，结合解释图可以看出：模型将预测结果从 *base* 推动到了 0 附近，推动向 0 的特征有主成分 6、主成分 10、主成分 3、医院编码_NN_2 等，推动向 1 的特征有主成分 7。

将上述解释图的形式旋转 90 度然后水平并排放置，得到解释图的变体，可以得到多样本的解释分析图，如图 16 所示：

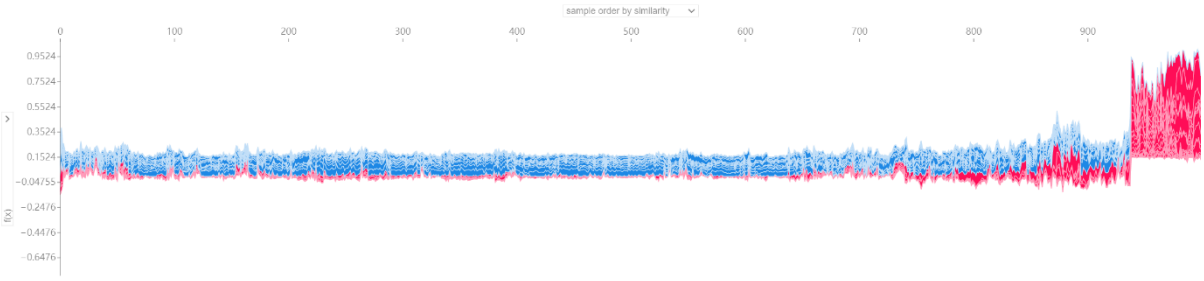

图 16 基于 SHAP 的多样本解释

通过图中上方和左方的选项卡，可以任意选择单个变量的多个样本对模型输出结果的影响。下图是主成分 1 对前 1000 个样本的模型输出结果 *f(x)*的影响。

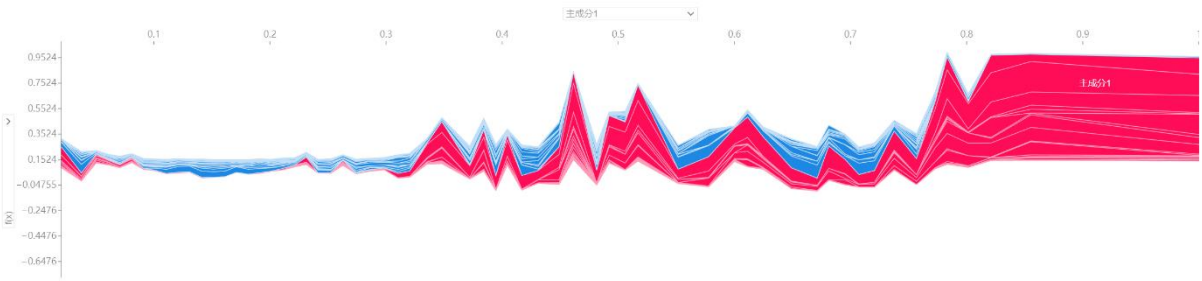

图 17 主成分 1 对前 1000 个样本的模型结果输出影响

还可以为每一个样本绘制其每个特征的 *SHAP* 值，展现哪些特征最重要，以及它们对数据集的影响范围，如图 18 所示：

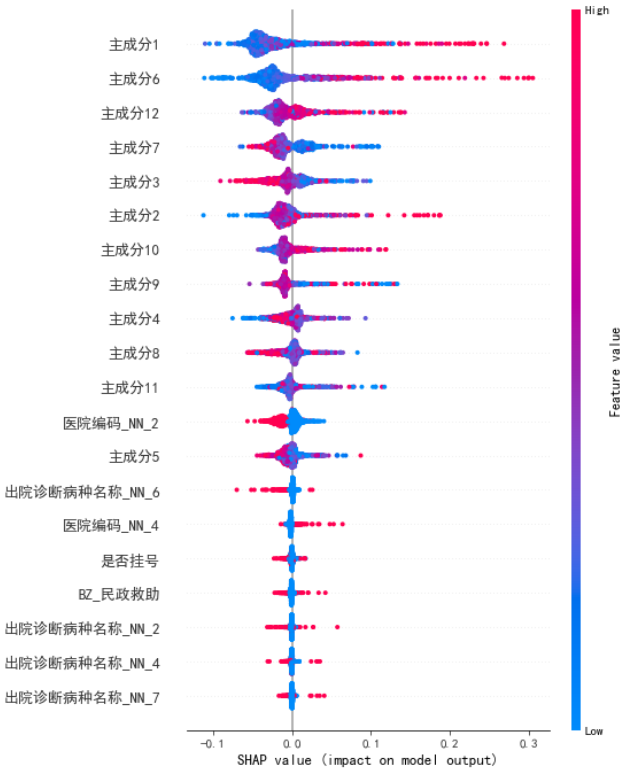

图 18 基于 *SHAP* 值的特征重要性

图中 Y 轴上的位置由特征确定，X 轴上的位置由 Shapley 值确定。一个点代表一个样本，点的颜色代表该个样本这个特征的值，红色高，蓝色低，点的位置代表某个样本这个特征的 *SHAP* 值。特征的 *SHAP* 值可以为负，且负值表示这个特征在这个样本上与预测值成反相关。以主成分 1 为例，该参数对模型的影响最大，当主成分 1 的值越大，模型的输出越大。

4.4.2 基于 *LIME* 的可解释性呈现

LIME(Local Interpretable Model-agnostic Explanations)技术是一种局部可解释性方法，能够解释机器学习模型的预测结果。*LIME* 技术的核心思想是通过生成局部线性模型来近似原始模型的预测结果。它通过在特定样本周围生成一组与原始数据类似的“虚拟样

本”，并使用这些虚拟样本来训练一个解释性模型（如线性回归模型）。然后通过分析这个解释性模型，可以获得对该样本预测的解释。

相较于 *SHAP* 呈现的特征对整体预测结果的影响以及全局模型行为的解释，*LIME* 提供了局部可解释性，重点解释单个样本或一小组样本的预测结果，帮助用户理解模型在特定实例上的决策过程。

选择了 *SHAP* 解释器来对模型进行可解释性的分析和展示后，使用 *LIME* 解释器对模型进一步分析，可以更加全面的对模型的预测结果解释分析，如图 19 所示：

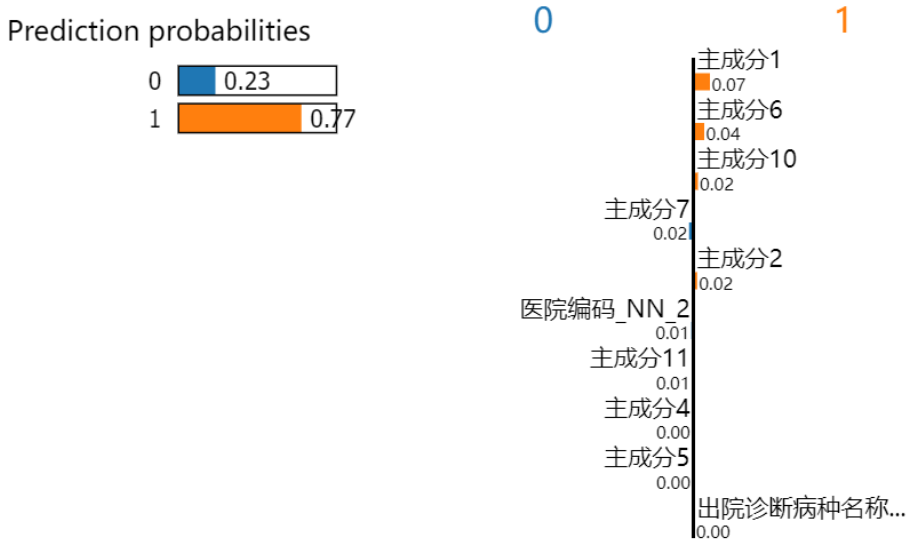

图 19 基于 *LIME* 的解释

上图表示模型以 77% 的置信度预测该样本的分类结果为类别 1，并且主成分 1、主成分 6、主成分 10、主成分 2 等特征推动分类结果趋向 1，主成分 7、医院编码_NN_2、主成分 11、主成分 4、主成分 5 等特征推动分类结果趋向 0。

4.4.3 可解释性的总结

本项目首先使用 *SHAP* 解释器呈现了所构建模型的预测结果的整体解释，输出了基于 *SHAP* 的多样本解释和每个样本点的特征影响程度；然后使用 *LIME* 解释器关注单样本的预测结果解释，得到了单个样本分类结果中各特征的影响程度。

SHAP 和 *LIME* 解释器的整体和局部解释的相互补充，提供了模型决策的深入洞察。*SHAP* 通过分配特征对预测的贡献度，提供了全局解释性视角。*LIME* 则专注于局部解释，通过构建局部模型揭示模型在特定情况下的决策逻辑。这种全局与局部解释性的结合，增强了模型透明度，并为模型改进提供了支持。

五、 业务实践与附加价值探索

5.1 业务实践角度的模型价值

在医疗保险欺诈检测领域，模型的建立与求解不仅需要关注算法的准确性和效率，还需要从业务实践的角度出发，评估模型在实际应用中的价值。

5.1.1 提高欺诈检测效率

构建的医疗保险欺诈检测模型能够自动化地分析大量的医疗数据，识别出异常模式和潜在的欺诈行为。这种自动化处理方式显著提高了欺诈检测的速度和效率，使得医疗机构和保险公司能够在较短的时间内处理更多的案件，从而更快地响应和解决欺诈问题。

5.1.2 降低医疗保险成本

医疗保险欺诈行为会导致医疗保险基金的不必要支出，增加了医疗机构和保险公司的运营成本。通过有效识别和预防欺诈行为，模型有助于减少这些不必要的支出，从而降低整体的医疗保险成本。此外，模型还能够通过预测未来的欺诈趋势，帮助机构提前采取措施，进一步降低潜在的经济损失。

5.1.3 增强风险管理能力

模型提供了一种量化的风险管理工具，使得医疗机构和保险公司能够更好地评估和管理与医疗保险欺诈相关的风险。通过对欺诈行为的预测和分析，机构能够制定更加有效的风险控制策略，如调整保险政策、优化审核流程等，从而提高整体的风险管理水平。

5.1.4 提升公众信任度

一个有效的医疗保险欺诈检测系统能够提升公众对医疗保险体系的信任度。当公众了解到医疗保险机构正在积极采取措施打击欺诈行为时，他们对系统的公正性和透明度会有更高的评价。这种信任的提升有助于增强公众对医疗保险制度的支持，促进医疗保险市场的健康发展。

5.2 附加价值的拓展和丰富

除了直接的业务价值外，医疗保险欺诈检测模型还可以通过以下方式拓展和丰富其附加价值。

5.2.1 政策制定与优化

模型的预测结果和分析报告可以为政策制定者提供数据支持，帮助他们更好地理解医疗保险欺诈的现状和趋势，从而制定或优化相关政策和法规。例如，模型可以揭示哪些类型的医疗服务更容易发生欺诈行为，或者哪些地区的欺诈行为更为普遍，这些信息对于政策制定者来说是非常宝贵的。

5.2.2 教育与宣传

通过模型分析得到的欺诈行为特征和模式可以用于教育和宣传材料的制作，提高公众对医疗保险欺诈行为的认识，增强自我防范意识。此外，模型还可以帮助教育公众如何正确使用医疗保险资源，避免无意中的欺诈行为。

5.2.3 跨行业合作

医疗保险欺诈检测模型的成功应用可以促进跨行业合作，例如与银行、信贷机构共享欺诈行为的识别和预防经验，共同提高整个社会的风险管理水平。这种合作有助于构建一个更加全面的风险防控网络，减少欺诈行为对社会经济的影响。

5.2.4 技术创新与发展

模型的开发和应用推动了人工智能和大数据分析技术在医疗保险领域的创新和发展。这些技术的进步不仅可以应用于医疗保险欺诈检测，还可以扩展到其他领域，如疾病预测、健康管理等。此外，模型的不断优化和升级也为相关技术的研究提供了实践平台，促进了技术创新的持续发展。

5.3 结论

综上所述，医疗保险欺诈检测模型在业务实践中具有显著的价值，能够有效提高欺诈检测的效率和准确性，降低医疗保险成本，增强风险管理能力，并提升公众对医疗保险体系的信任度。

同时，模型的应用还能够拓展和丰富其附加价值，包括为政策制定提供数据支持、提高公众教育水平、促进跨行业合作以及推动技术创新。随着技术的不断进步和应用的深入，模型将在医疗保险领域发挥越来越重要的作用，为社会经济的健康发展做出更大的贡献。

---

[1] He H, Wang J, Graco W , et al. Application of neural networks to detection of medical fraud [J]. Expert Systems with Applications, 1997, 13(4):329-336.

[2] Aral K D, Guvenir H A, Sabuncuoglu I, et al. A prescription fraud detection model[J]. Computer Methods and Programs in Biomedicine, 2012, 106(11):11-20.

[3] 王超, 韩可欣, 黄登一. 基于神经网络的医保欺诈主动发现模型[J]. 数字技术与应用, 2016(05):75-76+78.

[4] 狄萱. 基于孤立森林和随机森林的医保欺诈识别系统[D].南京邮电大学,2022.DOI:10.27251/d.cnki.gnjdc.2021.000436.

[5] 林杰新. 基于数据模式识别整合框架的 SOFM-SVM 模型及其应用[D]. 暨南大学, 2005.

[6] Halgamuge S K, Glesner M. Neural networks in designing fuzzy systems for real world applications [J]. Fuzzy sets and systems, 1994, 65(1): 1-12.